

Veeproovide vastavuse tõenäosuslik hindamine

Terviseameti avaandmete põhjal

TalTech ITI8612 — Masinõppe lõpp-projekti aruanne

Anton Sokolov

6. mai 2026

1. Probleem ja eesmärk

Terviseamet avaldab Eesti veeproovide laboratoorseid tulemusi avaandmetena (supluskoht, ühisveevärk, basseinid, joogiveeallikad). Iga proovi kohta on fikseeritud mikrobioloogilised ja keemilised näitajad ning ametlik vastavuse hinnang (vastab / ei vasta). Käsitsi ülevaatus on aeglane ja kallid.

Käesoleva projekti eesmärk on luua **binaarne klassifikaator**, mis ennustab proovi vastavust normile mõõtmistulemuste põhjal, ning hinnata, **kui hästi selline mudel sobib riskipõhise valiku tööriistana**. Tähtsaim mõõdik on **recall klassi 0 (rikkumine) suhtes** — vale-negatiivne ennustus (“kõik korras”, kui tegelikult mitte) seostub mikrobioloogiliste riskidega (nt *E. coli*) ja on praktiliselt halvem kui vale-positiivne (“liigne alarm”).

2. Andmed

Kasutame avaandmeid aadressilt vtiav.sm.ee, perioodist **2021–2026**, neljast domeenist (supluskoht , veevärk , basseinid , joogivesi). Andmed laaditakse ja parsitakse Pythonis (`src/data_loader.py`); kõik aastad kombineeritakse ühte tabelisse.

Suurus	Väärtus
Proove kokku	69 071
Rikkumisi (klass 0)	8 262 (12,0 %)
Vastab normile (1)	60 809 (88,0 %)
Treening / test	55 256 / 13 815 (80/20 stratifitseeritud)
Tunnuseid pärast feature engineeringut	70

Märkimisväärsed meetodilised aspektid:


- **Asukohtade dedupliitseerimine.** Terviseamet nimetab samu objekte aastate vahel ümber (nt *Harku järve supluskoht* → *Harku järve rand*). Tehniline parandus `location_key` (lowercase + objekti-tüübi sufiks) eemaldus, `data_loader.normalize_location` elimineerib pseudoduplikaadid.
- **Klasside tasakaalutus.** Lahendatud `class_weight="balanced"` ja lävendi optimeerimisega; **SMOTE-d ja sünteetilist üledisaktiivimist tahtlikult ei kasutatud**, et hoida vooluhulga kalibreeritust ja vältida sünteetiliste lähedaste-naabrite leket testkomplekti.
- **Pool-veenormide parandus.** Faasis 10 (andmete-kvaliteedi audit) avastasime, et meie esialgsed pool/spa-normid (vaba kloor [0,2; 0,6] mg/l) ei vasta Sotsiaalministri määrusele 49/2019, Lisa 4: õiged piirid on **[0,5; 1,5] mg/l** (vaba kloor) ja **≤ 0,5 mg/l** (seotud kloor). Pärast paranduse sisseviimist langes valedes märgete arv 288 ning citizen-service'i agree-rate ametliku hinnanguga tõusis 81,5 %-lt 90,8 %-ni (+9,3 pp).

3. Metoodika


Kogu töövoog on dokumenteeritud kuues järjestikusel Jupyteri märkmikus (`notebooks/01 – 06`):

1. **Tunnuste konstrueerimine** (`src/features.py`): toornäitajad + suhted normiga (`*_ratio`), ajalised tunnused (kuu, aasta, on-suvi), puuduva väärtuse indikaatorid (`*_missing`), domeen ja maakond (one-hot / fit-on-train, leket vältides).
2. **Imputeerimine ja skaleerimine** mediaaniga + `StandardScaler` — `fit` ainult treeningkomplektil.
3. **Mudelite võrdlus** neljal algoritmil (sklearn): Logistic Regression (baseline), Random Forest, Gradient Boosting, LightGBM.
4. **Lävendi optimeerimine.** `evaluate.best_threshold_max_recall_at_precision` maksimeerib recall klassi 0 jaoks tingimusel `precision ≥ 0,7`, kasutades PR-kõverat. Tavalävend 0,5 ei ole õige, kui FN-id maksavad rohkem kui FP-d.
5. **Kalibreerimine.** Isotooniline regressioon (`CalibratedClassifierCV`) viib ennustatud tõenäosused vastavusse tegelike sagedustega (vt joonist).
6. **Robustsus.** Lisaks juhuslikule splitile teostasime ajalise kross-valideerimise (`TimeSeriesSplit` , `n=5`) — metrikud jäävad samasse suurusjärku, mis kinnitab, et mudel ei õpi puhtalt aastapõhist mustrit.

4. Tulemused



Klasside tasakaal



ROC-kõverad neljal mudelil (test-komplekt)

Mudel	ROC-AUC	Recall (rikk.)	Precision (rikk.)	F1 (rikk.)
Logistic Regression	0,9509	0,8656	0,5757	0,6915
Random Forest	0,9862	0,9207	0,8445	0,8810
Gradient Boosting	0,9915	0,9619	0,8341	0,8934
LightGBM	0,9954	0,9510	0,9003	0,9249

LightGBM annab parima tasakaalu: ROC-AUC 0,995, F1 (rikk.) 0,925, samas kui Gradient Boosting saavutab pisut kõrgema rikkumiste recall'i (0,962) madalama precision'i hinnaga (0,834). Tegevuses sõltub valik tagajärgede asümmeetriast — vajadusel toetab `best_threshold_max_recall_at_precision` üleminekut ühe ja teise vahel ilma ümberõppimiseta.

SHAP-analüüsi kohaselt (LightGBM, 800 testproovi alamvalim) on viis peamist drivert: `iron_missing`, `combined_chlorine`, `free_chlorine`, `colonies_37c_missing`, `ph_missing`. Tähelepanuväärne on **puuduvuse indikaatorite domineerimine** — `*_missing` lipud kannavad infot proovi *tüübi* kohta (basseini- vs joogiveeproovid mõõdavad erinevaid parameetreid) ja sellest tuletatud baseline-riski. Tehnilised parameetrid (`coliforms`, `pH`, `oxidizability`) järgnevad. See selgitab, miks iga eraldi tunnus ei pea olema norme ületav, et mudel klassifitseeriks proovi rikkumiseks.

Sesoonne signaal. Suplusvee proovides on rikkumiste osakaal suvel umbes 4–5 korda kõrgem kui kevadel (vt `figures/seasonal_violations.png`).

5. Piirangud ja eetika

- **Sihtmuutuja on sisendi funktsioon.** Vastavuse hinnang tuleneb suuresti samade näitajate võrdlusest normidega — ROC-AUC > 0,99 peegeldab seetõttu ülesande **struktuuri**, mitte mudeli eraldiseisvat ennustusvõimet (vt `docs/ml_framing.md`).

- **Mudel ei mõõda vett.** Ta ei tuvasta loobunud või mõõtmata saasteaineid; ennustus kehtib ainult pärast laboriuuringut.
- **Avalike andmete täielikkus.** Faasi 10 audit leidis 2 164 proovi (3,1 %), kus ametlik hinnang on “rikkumine”, kuid ükski avaldatud parameeter normi ei ületa. See viitab, et osa otsustest tugineb avaldamata andmetele (vt `docs/phase_10_findings.md`).
- **Põhjuslikkus puudub.** SHAP näitab näitaja panust ennustusse, mitte füüsilist saastepõhjust.
- **Mudel ei prognoosi tulevikku.** Iga proov on punktmõõtmine; mudel klassifitseerib selle, mitte ei ennusta vee seisundit homme.

6. Praktiline rakendus

Tulemused on viidud avalikku teenusesse h2oatlas.ee: 2 196 asukoha interaktiivne kaart, kahe kihiga — *ametlik staatus* ja *mudeli risk* (P(rikkumine) neljast mudelist valitavalt). Liides on mitmekeelne (RU/ET/EN), lisab selgituse, et teenus **ei asenda ametlikku hinnangut, ei ennusta tuleviku kvaliteeti ega anna meditsiinilisi soovitusi**.

7. Õppetunnid (vastus juhendaja märkusele)

Juhendaja juhtis tähelepanu, et **andmete töötlemine, klasside tasakaalutus ja mitme mudeli võrdlus võivad nõuda rohkem aega kui algselt eeldatud**. Selle peame kinnitama:

- **Skoobi haldus** — alustasime kahe domeeniga (`supluskoha` , `veevark`), laienesime nelja peale alles peale baastorustiku stabiliseerumist.
- **Andmete-kvaliteedi audit (Phase 10)** lisandus alles pärast esimese mudeli ootamatuid metrikuid — see avastas pool-normide vea ja aitas vältida vale järelduse “mudel ennustab paremini kui ametnik”.
- **Tasakaalutus** lahendati kombinatsioonis (`class_weight="balanced"` + lävendi tuning), mitte sünteetilise üledisaktiivimisega — see hoiab kalibreerimise õigesti tõlgendatavana.

Kõik töövoog on reprodutseeritav: `python scripts/export_submission_figures.py` (arvud) → `python scripts/build_presentation.py` (slaidid) → `bash scripts/build_report_pdf.sh` (käesolev PDF).

Viited: kõik joonised ja koondtabelid on kataloogis `submission/figures` ja `submission/tables`. Mudelite valideerimise üksikasjad — `notebooks/04` , `06` ; SHAP ja kalibreerimine — `notebooks/06`. Lähtekood — repository `water-quality-ee` (CC-BY 4.0 + MIT, vt `LICENSE`).